QWEN MEETUP TOKYO · LOCAL LLM EXPERIMENTS

Can Qwen Improve Itself on ARC?

自己生成データから、問題を解く力は伸ばせるのか?

Qwen3 · ARC-AGI-2 · Apple Silicon · experiments through 2026-11-05

今回の問い

1 · Solve

例からルールを推測し、未知のグリッドを解けるか?

2 · Generate

学習に使える問題とプログラムを自分で作れるか?

3 · Improve

そのデータで学習し、独立した問題で改善するか?

> **結果：学習の仕組みは動いた。ARCの正答率向上はまだ示せていない。**

Overview: ../nb/00_overview.ipynb

ARCは「例からルールを見つける」課題

入力

色付きグリッドの入力と出力の例を複数見る。

新しい入力に同じ変換を適用する。

今回の方法

Qwenに変換用Pythonを書かせる。

隔離環境で実行し、独立した出力で検証する。

> **動くコードと、正しい変換は違う。**

../docs/p3c-live-audit.md · Evaluation labels are kept out of prompts

まずは実問題を解いて、学習データを集める

1 / 260

independently verified solutions

4B: 0/220 · 8B: 1/40

通常の学習ゲートは、検証済み5件。

../docs/p3b-local.md · 1-example pilot was separate from the normal five-record gate

1件の別パイロット

- 8Bで実際にQLoRAを実行
- ベース重みを維持しadapterを保存
- 比較時に4/5タスクでエラー → rollback

探索方法を変えても、正解は増えなかった

E2 · 4つの戦略

同じ5問で比較。

0 / 5

各戦略のheld-out正解

E3 · 追加収集

選択した方法で19問に着手。

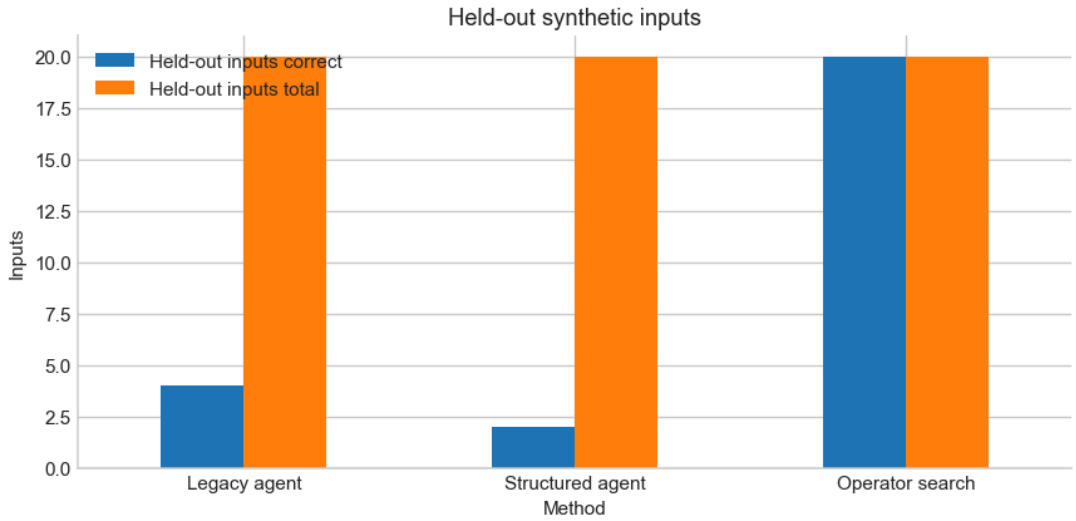
0

独立検証を通った解答

E2の選択は同点時のfallback。優れた方法を見つけた証拠ではない。

../docs/e4-analysis.md · ../artifacts/e2-live-full-reselected/report.md

単純な変換なら、人間が設計した探索は強い



../docs/e4-analysis.md · 10 synthetic tasks, two held-out inputs each

20 / 20

operator search · 合成held-out入力

モデルのコード生成は4/20。

> 問題は探索対象の変換族から作成。一般的なARC性能は示さない。

E5: 自分で作った問題を、自分で解けるか

Generator

Qwenが変換プログラムを生成。

一般的な実行エラーのフィードバックで修正し、1問を作成。

Solver

生成コードを見ずに例から解く。

0 / 2

独立検証に通った候補

> **問題を作ることと、独立して解くことは別。**

../docs/e5-autonomous-rsi.md · live Qwen3-8B smoke

E6：生成プログラムを教師にすると?

2 / 5

distinct verified task / Oracle shapes

E6 bootstrap

5件に届かず、QLoRAはスキップ。

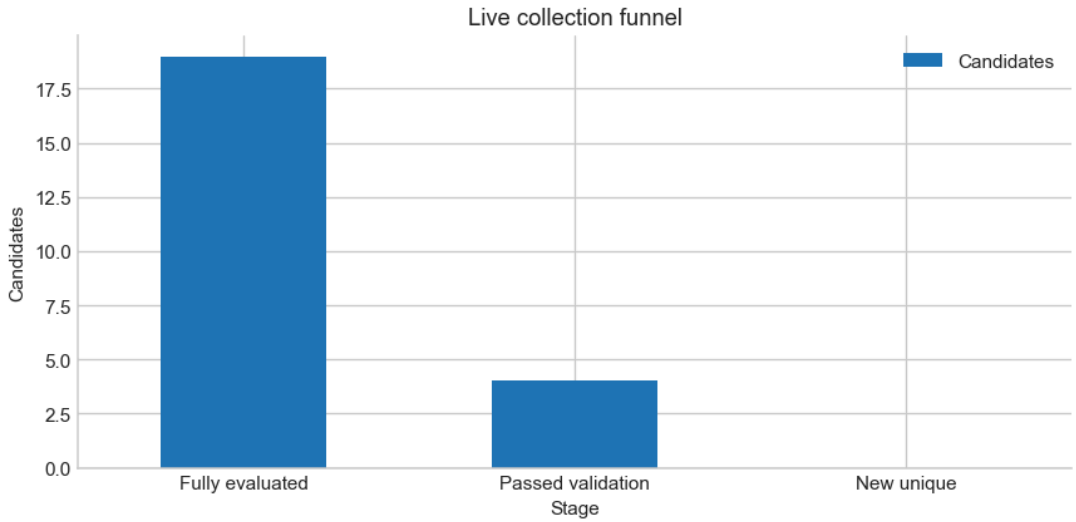
Generator distillation

生成したプログラムを教師として使う。

> これは自己解答に成功した例ではない。

../docs/e6-self-generated-curriculum.md · Historical records later lacked a pinned static-checker dependency

E6-F：修正しても、新しいOracleは増えない



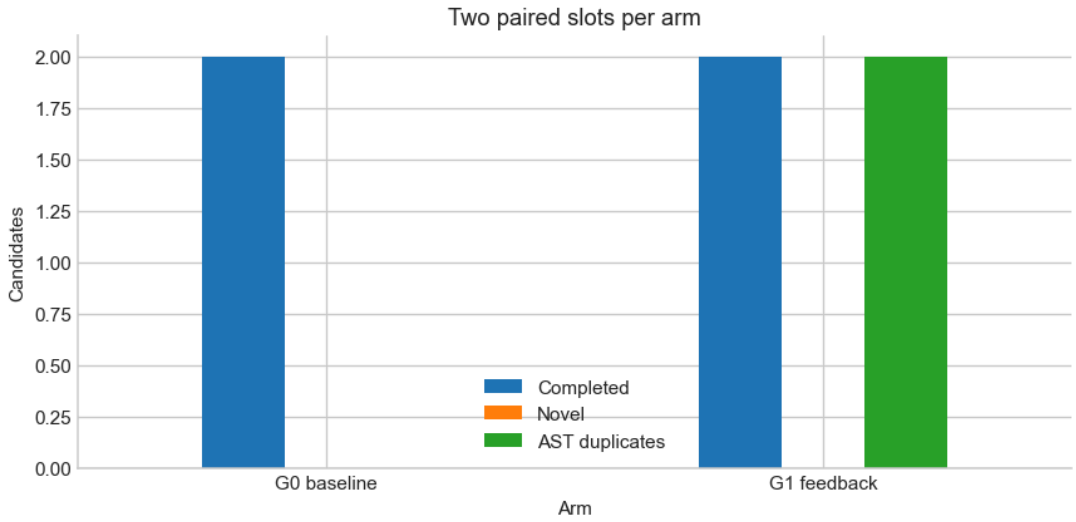
4件が検証を通過。

ただし4件とも既存プログラムと重複。

> **新規は 0 件**

../docs/e6f-oracle-reliability.md · 19 fully evaluated; one additional candidate was budget interrupted

E6-G / E7：重複を伝えると改善する?



同じ条件で、重複についての通知だけを変えた。

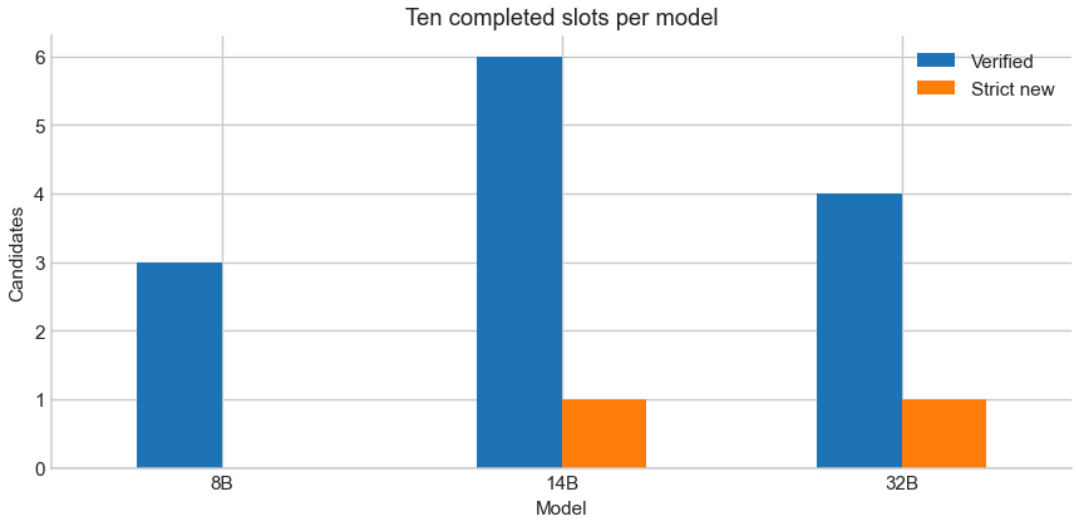
0 vs 0

E7 · new Oracles, two slots per arm

改善は観察されず。小標本では効果の有無を断定できない。

../docs/e6g-autonomous-curriculum-diversity.md · ../docs/e7-autonomous-rsi-feasibility.md

E8：モデルを大きくすると?



各モデル10 slot、同じ検証条件。

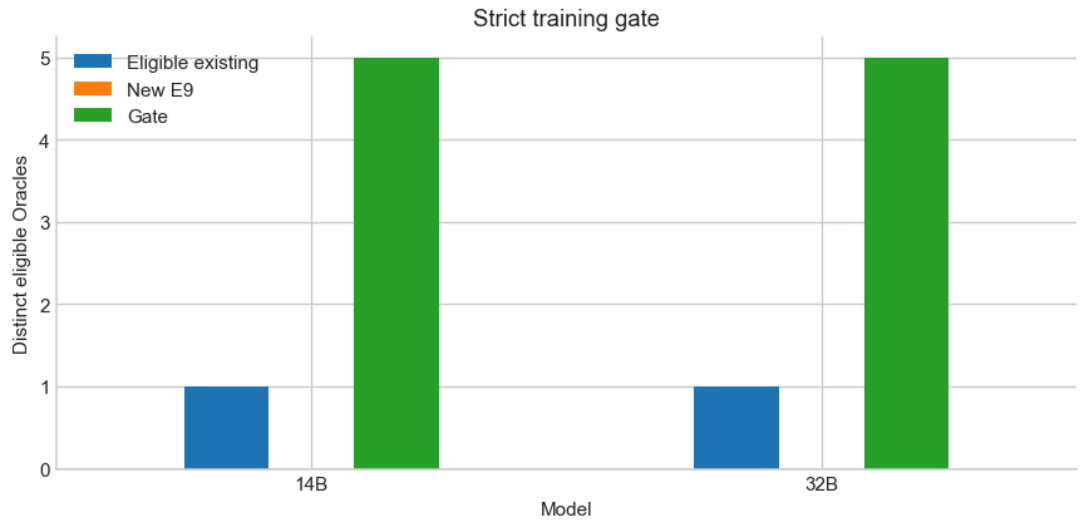
0 · 1 · 1

strict new Oracles

8B · 14B · 32B
全モデルが5件未満。

../docs/e8-full-rerun-20261104.md · corrected preregistered rerun; small sample

E9：14Bと32Bを分けて収集



../docs/e9-dual-model-rsi.md · 14B extra: 30 slots; 32B initial: 10 slots

各モデルが使える既存Oracleは1件。

監査済み追加収集の新規は**両モデルとも0件**。

> 1/5：学習も、adapter比較も未実施。

「検証済み」を分解する

実行可能

安全に動き、出力形式を満たす。

Oracle検証

非公開probeなどの条件を通る。

Strict new

重複と出自の条件も満たす。

> 旧E8 Fullは実行依存コードのhashが欠落。修正版の別runで再比較した。

../docs/e8-full-rerun-20261104.md · ../docs/e9-dual-model-rsi.md

TAKEAWAY

Training ≠ Improvement

学習できたことと、未知の問題で改善したことを分けて測る。

1 · Data

独立検証と多様性がボトルネック

2 · Provenance

依存コードも含めて事前固定

3 · Evaluation

同条件の比較で転移を測る

Explore the evidence: ../nb/README.md